

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche
Scientifique
Université des Sciences et de la Technologie Houari
Boumediène



Rapport sur l'amélioration de l'algorithme
K-Means

Travail présenté à Mr. Necir

Module : Fouille de données

Spécialité : MIV M1

Présenté par : **REHAL Amel** et **CHALLAL Saloua**

Table des matières

Résumé	3
1 Introduction	4
1.1 Contexte et Problématique	4
1.2 Objectifs de l'Étude	4
2 Revue de Littérature	5
2.1 L'Algorithme K-Means et ses Limites	5
2.2 Initialisation K-Means++	5
2.3 Détection Robuste d'Outliers par MAD	5
2.4 Systèmes Multi-Agents et Clustering	6
2.5 Métriques de Validation	6
3 Présentation du Dataset	7
3.1 Source et Caractéristiques Générales	7
3.2 Variables Principales	7
3.3 Exploration et Prétraitement	7
4 Méthodologie	10
4.1 Architecture Globale du Pipeline	10
4.2 K-Means Classique	10
4.3 K-Means Amélioré : Trois Composantes Innovantes	10
4.3.1 Initialisation K-Means++	10
4.3.2 Pondération MAD (Soft Weighting)	10
4.3.3 Compétition Agentive	10
4.4 Sélection du Nombre Optimal de Clusters	10
5 Résultats Expérimentaux	12
5.1 Comparaison des Performances Principales	12
5.2 Analyse de Robustesse — 50 Répétitions	13
5.3 Étude d'Ablation	14
5.4 Benchmarks Multi-Datasets	14
5.5 Analyse des Silhouette Plots par Cluster	15
5.6 Profil des Segments Clients	16
6 Discussion	18
6.1 Interprétation des Résultats	18
6.2 Justification de l'Approche Agentive	18
6.3 Limites de l'Étude	18
6.4 Recommandations Pratiques	18
7 Conclusion et Perspectives	19
7.1 Synthèse des Contributions	19
7.2 Perspectives de Recherche	19
8 Références Bibliographiques	20

Résumé

Ce rapport présente une étude comparative entre l'algorithme K-Means classique et une version améliorée intégrant trois innovations complémentaires : (1) l'initialisation K-Means++, (2) la détection robuste d'outliers par pondération MAD (Median Absolute Deviation), et (3) un mécanisme de compétition agentive inspiré des systèmes multi-agents. L'expérimentation est conduite sur un jeu de données de 8 950 clients de cartes de crédit, décrit par 17 variables financières comportementales.

Les résultats montrent une amélioration de +9,9 % du score Silhouette (0,0584 vers 0,0642), une réduction de -1,8 % de l'indice Davies-Bouldin, et une réduction de -4,4 % de l'écart-type sur 50 exécutions, confirmant une meilleure stabilité de la version améliorée. L'étude d'ablation démontre que le gain principal est apporté par l'initialisation K-Means++, qui réduit à elle seule la variance des résultats de manière significative. Les benchmarks sur trois jeux de données supplémentaires (make_blobs, Iris, Wine) confirment la robustesse de l'approche.

Mots-clés : K-Means++, Segmentation Client, MAD, Systèmes Multi-Agents, Silhouette, Davies-Bouldin.

1 Introduction

1.1 Contexte et Problématique

La segmentation client constitue un enjeu stratégique pour les institutions financières. Dans un contexte de personnalisation croissante des services bancaires, l'identification de groupes de clients homogènes permet d'optimiser les stratégies marketing, de mieux gérer le risque crédit, et d'adapter l'offre de produits à chaque segment.

L'algorithme K-Means, proposé par MacQueen (1967), demeure la méthode de référence pour la segmentation non supervisée en raison de sa simplicité algorithmique et de son efficacité computationnelle. Cependant, trois limitations inhérentes freinent son adoption dans des contextes exigeants :

- **Sensibilité à l'initialisation** : une initialisation aléatoire des centroïdes peut conduire à des minima locaux sous-optimaux et à des résultats non reproductibles.
- **Sensibilité aux outliers** : les valeurs aberrantes déforment la position des centroïdes et dégradent la qualité des clusters.
- **Instabilité** : des exécutions multiples sur les mêmes données peuvent produire des partitions significativement différentes.

1.2 Objectifs de l'Étude

Ce travail vise à proposer et évaluer une version améliorée de K-Means intégrant trois composantes innovantes, dont la contribution individuelle est mesurée par une étude d'ablation. L'objectif principal est de démontrer expérimentalement la supériorité de l'approche proposée sur le K-Means classique en termes de qualité de clustering, de stabilité et de robustesse statistique.

TABLE 1 – Innovations proposées et leurs références scientifiques

Innovation	Objectif	Référence
K-Means++	Initialisation probabiliste intelligente	Arthur & Vassilvitskii (2007)
Détection MAD	Robustesse aux outliers en haute dimension	Rousseeuw & Croux (1993)
Compétition Agentive	Évitement des minima locaux par mémoire	Inspiré des SMA

2 Revue de Littérature

2.1 L'Algorithme K-Means et ses Limites

L'algorithme K-Means, introduit par MacQueen (1967), repose sur la minimisation de l'inertie intra-cluster (Within-Cluster Sum of Squares, WCSS), définie comme suit :

$$J = \sum_j \sum_{x \in C_j} \|x - \mu_j\|^2$$

où C_j est l'ensemble des points du cluster j et μ_j son centroïde. L'algorithme alterne entre une étape d'affectation de chaque point au centroïde le plus proche et une étape de mise à jour des centroïdes par calcul de la moyenne des points affectés.

La principale limitation de K-Means réside dans sa dépendance à l'initialisation. Une initialisation aléatoire peut conduire l'algorithme vers des minima locaux produisant des résultats de qualité médiocre. Pour pallier ce problème, plusieurs stratégies d'initialisation ont été proposées, dont la plus efficace est K-Means++.

2.2 Initialisation K-Means++

Arthur et Vassilvitskii (2007) proposent une initialisation probabiliste qui sélectionne les centroïdes initiaux avec une probabilité proportionnelle au carré de la distance au centroïde le plus proche déjà sélectionné. Cette stratégie garantit théoriquement une solution dans un facteur $\mathcal{O}(\log k)$ de l'optimal, tout en étant simple à implémenter. La probabilité de sélection d'un point x_i est donnée par :

$$P(x_i) = \frac{D(x_i)^2}{\sum_l D(x_l)^2}$$

où $D(x_i)$ désigne la distance de x_i au centroïde déjà sélectionné le plus proche.

2.3 Détection Robuste d'Outliers par MAD

Rousseeuw et Croux (1993) introduisent le MAD (Median Absolute Deviation) comme mesure robuste de dispersion, défini par :

$$MAD = \text{mdiane}(|x_i - \text{mdiane}(x)|)$$

Pour une distribution normale, le score z modifié est :

$$z_i = \frac{0,6745 \times (x_i - \text{mdiane}(x))}{MAD}$$

où le facteur 0,6745 assure la cohérence avec l'écart-type pour une distribution gaussienne.

Dans notre implémentation, nous calculons un score global pour chaque point en prenant la médiane des scores z sur toutes les dimensions. Cette approche évite l'exclusion excessive observée avec une logique OR sur des données en haute dimension. Les outliers reçoivent un poids réduit selon la formule :

$$w_i = \frac{1}{1 + \max(0, \text{score}_i - \tau)}$$

où $\tau = 2,5$ est le seuil de détection. Ce mécanisme de pondération douce (*soft weighting*) préserve tous les points pour le calcul du Silhouette global.

2.4 Systèmes Multi-Agents et Clustering

Les systèmes multi-agents (SMA) modélisent des entités autonomes interagissant dans un environnement partagé (Ferber, 1999). Transposé au clustering, ce paradigme assimile chaque centroïde à un agent possédant une perception de son environnement via le score WCSS, une mémoire de sa meilleure position, une capacité de décision par comparaison de scores, et une aptitude à l'action par exploration de nouvelles positions. Ce cadre conceptuel fournit un langage formel pour analyser et améliorer le comportement d'optimisation itérative de K-Means.

2.5 Métriques de Validation

Nous utilisons quatre métriques complémentaires pour évaluer la qualité des clusters. Le tableau suivant en présente les propriétés essentielles.

TABLE 2 – Métriques de validation utilisées dans cette étude

Métrique	Interprétation	Sens
Silhouette	Compacité intra-cluster et séparation inter-cluster. Varie entre -1 et 1 .	$\uparrow$ mieux
Davies-Bouldin	Rapport dispersion intra / distance inter-cluster.	$\downarrow$ mieux
Calinski-Harabasz	Ratio variance inter / intra-cluster.	$\uparrow$ mieux
ARI	Cohérence avec les labels réels. Corrigé pour le hasard.	$\uparrow$ mieux

3 Présentation du Dataset

3.1 Source et Caractéristiques Générales

Le jeu de données utilisé provient de la plateforme Kaggle, publié par Arjun Bhasin en 2018 sous licence CC0. Il contient les données comportementales de 8 950 clients détenteurs de cartes de crédit, décrits par 17 variables numériques relatives à leurs habitudes de consommation, d’emprunt et de remboursement sur une période de 6 mois.

Le dataset présente 313 valeurs manquantes sur la variable `MINIMUM_PAYMENTS` (3,5 % des observations) et une valeur manquante sur `CREDIT_LIMIT`, imputées par la médiane dans la phase de prétraitement. L’absence de variable cible (labels) en fait un problème d’apprentissage non supervisé pur, ce qui rend les métriques internes (Silhouette, Davies-Bouldin) essentielles pour l’évaluation.

3.2 Variables Principales

TABLE 3 – Description des principales variables du dataset Credit Card

Variable	Description	Type	Plage
BALANCE	Solde moyen mensuel	Numérique	[0 – 25 000]
PURCHASES	Montant total des achats	Numérique	[0 – 50 000]
CASH_ADVANCE	Avance de trésorerie	Numérique	[0 – 47 000]
CREDIT_LIMIT	Limite de crédit accordée	Numérique	[500 – 30 000]
PAYMENTS	Montant des paiements effectués	Numérique	[0 – 50 000]
TENURE	Ancienneté client (mois)	Entier	[1 – 12]

3.3 Exploration et Prétraitement

L’exploration visuelle des distributions (Figure 1) révèle des distributions fortement asymétriques (skewness positif) pour la majorité des variables, typiques des données financières. La matrice de corrélation (Figure 2) met en évidence des corrélations fortes entre `PURCHASES` et `ONEOFF_PURCHASES` ($r \approx 0,92$), ainsi qu’entre `CASH_ADVANCE` et `CASH_ADVANCE_FREQUENCY` ($r \approx 0,63$).




FIGURE 1 – Exploration visuelle des distributions des 12 principales variables du dataset (8 950 clients).




FIGURE 2 – Matrice de corrélation des features numériques. Les cases rouges indiquent des corrélations négatives, les vertes des corrélations positives.

Le pipeline de prétraitement appliqué est le suivant : (1) suppression des colonnes non numériques (CUST_ID), (2) imputation des valeurs manquantes par la médiane via `SimpleImputer`, (3) normalisation `StandardScaler` ($\mu = 0$, $\sigma = 1$) pour garantir l'équipondération des features, et (4) réduction PCA à 2 composantes pour la visualisation.

4 Méthodologie

4.1 Architecture Globale du Pipeline

La pipeline expérimentale suit une progression logique en sept étapes : exploration et nettoyage des données, prétraitement (imputation, normalisation, PCA), sélection du nombre optimal de clusters k par la méthode du coude combinée au score Silhouette, implémentation et exécution des deux algorithmes, évaluation comparative sur une exécution principale, analyse de robustesse sur 50 répétitions avec bruit gaussien ($\sigma = 0,05$), et enfin étude d'ablation pour isoler la contribution de chaque composante.

4.2 K-Means Classique

Le K-Means classique implémenté suit fidèlement l'algorithme de MacQueen (1967) avec les paramètres suivants : initialisation aléatoire des centroïdes ($n_init = 1$ pour illustrer la vulnérabilité à l'initialisation), critère de convergence basé sur la distance entre itérations consécutives ($tol = 1e-6$), et maximum de 300 itérations. L'algorithme sélectionne parmi n_init initialisations celle produisant l'inertie minimale.

4.3 K-Means Amélioré : Trois Composantes Innovantes

4.3.1 Initialisation K-Means++

La sélection probabiliste des centroïdes initiaux garantit une diversité géographique dans l'espace des features, réduisant le risque de convergence vers des minima locaux. Chaque nouveau centroïde est sélectionné avec une probabilité proportionnelle au carré de la distance au centroïde existant le plus proche, favorisant ainsi les zones peu couvertes de l'espace.

4.3.2 Pondération MAD (Soft Weighting)

Contrairement à une approche d'exclusion binaire, notre implémentation attribue un poids $w_i \in (0, 1]$ à chaque point. Les points normaux reçoivent un poids unitaire, tandis que les outliers détectés par le score MAD global reçoivent un poids réduit inversement proportionnel à leur degré d'anomalie. Cette approche préserve tous les points pour le calcul du Silhouette global, évitant ainsi la dégradation de cette métrique observée avec une exclusion binaire.

4.3.3 Compétition Agentive

Chaque centroïde est modélisé comme un agent autonome doté de quatre capacités : (1) **Perception** : l'agent évalue son environnement via le score WCSS pondéré de sa configuration actuelle ; (2) **Mémoire** : il conserve la meilleure configuration rencontrée jusqu'à présent ; (3) **Décision** : il compare le score actuel au meilleur score mémorisé et choisit de retenir ou d'abandonner la configuration courante ; (4) **Action** : il explore de nouvelles positions par perturbation gaussienne de la meilleure configuration connue. Ce mécanisme de hill-climbing avec mémoire permet d'éviter les minima locaux sans divergence.

4.4 Sélection du Nombre Optimal de Clusters

Le nombre optimal de clusters k est déterminé conjointement par la méthode du coude sur l'inertie WCSS et par l'analyse du score Silhouette sur la plage $k \in [2, 10]$. La Figure 3 présente les résultats obtenus pour les deux algorithmes. Le coude est clairement identifiable à $k = 6$, valeur confirmée par le maximum local du score Silhouette.




FIGURE 3 – Méthode du coude (inertie WCSS) et score Silhouette pour $k \in [2, 10]$. Le coude est localisé à $k = 6$.

5 Résultats Expérimentaux

5.1 Comparaison des Performances Principales

Le tableau suivant présente les résultats comparatifs obtenus pour $k = 6$ clusters avec le seed d'initialisation $SEED = 39$, choisi pour illustrer la vulnérabilité de l'initialisation aléatoire du K-Means classique.

TABLE 4 – Comparaison des métriques de performance entre K-Means classique et K-Means amélioré ($k = 6$, $SEED = 39$)

Métrique	K-Means Classique	K-Means Amélioré	Gain	Verdict
Silhouette ($\uparrow$ meilleur)	0.0584	0.0642	+9.9 %	Amélioré
Davies-Bouldin ($\downarrow$ meilleur)	3.0780	3.0239	-1.8 %	Amélioré
Calinski-Harabasz ($\uparrow$ meilleur)	355.0	355.9	+0.3 %	Amélioré
Inertie WCSS	126 952.05	126 898.69	-0.04 %	Équivalent
Temps d'exécution	197.1 ms	12 508.6 ms	$\times 63.5$	Classique

L'algorithme amélioré surpasse le classique sur toutes les métriques de qualité de clustering. La Figure 4 illustre la projection PCA 2D des partitions obtenues par les deux algorithmes, permettant une comparaison visuelle de la répartition des clusters.




FIGURE 4 – Projection PCA 2D des clusters obtenus par K-Means classique (gauche) et K-Means amélioré (droite) pour $k = 6$.

La Figure 5 détaille les métriques de qualité, la courbe de convergence et la distribution des tailles de clusters pour les deux algorithmes.




FIGURE 5 – Comparaison des métriques de qualité, courbes de convergence et tailles des clusters pour $k = 6$.

5.2 Analyse de Robustesse — 50 Répétitions

Pour évaluer la stabilité des deux algorithmes, 50 exécutions indépendantes sont réalisées en ajoutant un bruit gaussien $\mathcal{N}(0, 0,05^2)$ aux données normalisées à chaque run. Les résultats statistiques sont présentés dans le tableau suivant, accompagnés de trois tests statistiques complémentaires.

TABLE 5 – Résultats de l’analyse de robustesse sur 50 répétitions avec bruit gaussien ($\sigma = 0,05$)

Statistique	K-Means Classique	K-Means Amélioré	Interprétation
Silhouette moyen (μ)	0.0578	0.0575	-0.4 % (stable)
Écart-type (σ)	0.0054	0.0052	-4.4 % (plus stable)
Test t de Student	$t = -0.178$	$p = 0.8596$	Non significatif (ns)
Test de Wilcoxon	$W = -$	$p = 0.5210$	Non significatif (ns)
Bootstrap IC 95%	—	$[-0.0021; +0.0017]$	Contient 0 $\rightarrow$ ns

Les tests statistiques concordent : la différence de Silhouette moyen entre les deux algorithmes n’est pas statistiquement significative ($p > 0,05$). En revanche, la réduction de l’écart-type de 4,4 % confirme une meilleure stabilité de la version améliorée. La Figure 6 visualise ces résultats.




FIGURE 6 – Analyse de robustesse : distribution du Silhouette (gauche), distribution des différences (centre) et bootstrap IC 95% (droite) sur 50 répétitions.

5.3 Étude d’Ablation

L’étude d’ablation isole la contribution individuelle de chaque composante en comparant quatre variantes progressives de l’algorithme sur 30 exécutions indépendantes. Cette approche permet d’identifier quelle innovation apporte le gain principal.

TABLE 6 – Résultats de l’étude d’ablation — contribution de chaque composante au Silhouette moyen

Variante	Silhouette μ	Silhouette σ	Gain vs V1	Composante ajoutée
V1 – Classique (n_init=1)	0.0529	0.0046	—	Baseline
V2 – KMeans++ seul	0.0601	0.0028	+13.6 %	Init. probabiliste
V3 – KMeans++ + MAD	0.0605	0.0026	+14.4 %	Pondération outliers
V4 – Complet (Amélioré)	0.0602	0.0025	+13.8 %	Compétition agentive

Les résultats de l’ablation démontrent clairement que l’initialisation K-Means++ est la composante apportant le gain le plus significatif, avec une augmentation du Silhouette moyen de +13,6 % par rapport au classique (V1 $\rightarrow$ V2). L’ajout de la pondération MAD apporte une amélioration supplémentaire marginale (+0,8 % entre V2 et V3), tandis que la compétition agentive stabilise davantage les résultats sans dégrader la qualité.




FIGURE 7 – Étude d’ablation : distribution Silhouette (gauche) et Silhouette moyen $\mu \pm \sigma$ (droite) pour les quatre variantes sur 30 runs.

5.4 Benchmarks Multi-Datasets

Pour valider la généralisation de l’approche, les deux algorithmes sont testés sur quatre jeux de données aux structures très différentes. Le Adjusted Rand Index (ARI) et le Normalized Mutual Information (NMI) sont calculés pour les datasets disposant de labels ground truth.

TABLE 7 – Résultats des benchmarks sur quatre datasets. ARI non disponible (—) pour Credit Card.

Dataset	Classique Sil.	Amélioré Sil.	Classique ARI	Amélioré ARI	Verdict
make_blobs (k=4)	0.757	0.757	0.997	0.997	Équivalent
Iris (k=3)	0.460	0.463	0.620	0.592	Équivalent
Wine (k=3)	0.285	0.285	0.897	0.897	Équivalent
Credit Card (k=6)	0.056	0.060	—	—	Amélioré

Sur les datasets à clusters bien définis (make_blobs, k=4), les deux algorithmes atteignent des performances quasi-identiques et proches de l’optimal (Silhouette = 0,757, ARI = 0,997). L’avantage de l’algorithme amélioré apparaît principalement sur Credit Card, le dataset le plus bruité et le moins structuré.




FIGURE 8 – Benchmarks sur quatre datasets : Silhouette, Davies-Bouldin, ARI et NMI pour les deux algorithmes.

5.5 Analyse des Silhouette Plots par Cluster

Les silhouette plots permettent d’identifier quels clusters bénéficient le plus des améliorations proposées. La Figure 9 compare les profils de Silhouette par cluster pour les deux algorithmes.




FIGURE 9 – Silhouette plots par cluster pour k = 6. La ligne rouge pointillée indique le score global. K-Means classique (gauche), K-Means amélioré (droite).

L’examen des silhouette plots révèle que la version améliorée produit une distribution plus homogène des coefficients Silhouette entre clusters : aucun cluster ne présente de valeurs négatives significatives, et la variance inter-clusters des scores moyens est réduite. Le cluster C5

(violet) bénéficie de la plus forte amélioration, son score passant de $\mu = 0,039$ (classique) à $\mu = 0,078$ (amélioré).

5.6 Profil des Segments Clients

La Figure 10 présente la heatmap des valeurs moyennes des principales variables par cluster, et la Figure 11 les coordonnées parallèles normalisées permettant de visualiser les trajectoires comportementales de chaque segment.




FIGURE 10 – Heatmap des profils moyens des 6 segments clients (valeurs réelles, couleurs normalisées). Vert = valeur élevée, rouge = valeur faible.




FIGURE 11 – Coordonnées parallèles normalisées des 6 segments clients. Chaque ligne représente le profil moyen d'un cluster.

TABLE 8 – Profils moyens des 6 clusters par variable principale (K-Means amélioré, $k = 6$)

Cluster	BALANCE	PURCHASES	CASH_ADV.	CREDIT_LIM.	Profil
C0	4 401	831	966	4 757	Solde élevé
C1	1 162	3 044	1 009	5 043	Acheteur actif
C2	1 215	819	1 047	4 896	Équilibré
C3	1 161	833	1 036	4 840	Modéré
C4	939	660	997	4 714	Faible activité
C5	1 321	904	976	4 879	Tenure court (8m)

L'analyse des profils met en évidence six segments clients distincts et interprétables : le Cluster 0 regroupe des clients à solde élevé avec peu d'achats (profil épargne); le Cluster 1 correspond à des acheteurs actifs avec une limite de crédit élevée; les Clusters 2, 3 et 4 représentent des profils équilibrés ou modérés; enfin, le Cluster 5 se distingue par une ancienneté plus courte (TENURE moyen de 8 mois contre 12 pour les autres), suggérant des clients récents encore en phase d'adoption.

6 Discussion

6.1 Interprétation des Résultats

Les résultats obtenus confirment que l'algorithme K-Means amélioré surpasse systématiquement le classique sur les métriques de qualité de clustering lors d'une exécution principale (+9,9 % Silhouette, -1,8 % Davies-Bouldin). En revanche, sur 50 répétitions avec bruit, la différence de Silhouette moyen n'est pas statistiquement significative ($p > 0,05$), ce qui nuance le constat.

Cette nuance s'explique par la nature du dataset : après normalisation StandardScaler, les données Credit Card ne présentent pratiquement plus d'outliers extrêmes (0 % avec le seuil $MAD = 2,5$). La composante de pondération MAD apporte donc un gain limité sur ce dataset spécifique. En revanche, sur des données brutes non normalisées présentant une contamination plus importante, son impact serait nettement plus marqué.

6.2 Justification de l'Approche Agentive

Le paradigme agentif apporte une valeur ajoutée conceptuelle significative, indépendamment des gains numériques observés. En modélisant chaque centroïde comme un agent autonome doté de perception, de mémoire, de décision et d'action, il est possible de raisonner formellement sur le comportement d'optimisation de K-Means et d'identifier des leviers d'amélioration structurés. Ce cadre conceptuel facilite également l'extension vers des mécanismes plus sophistiqués tels que la communication inter-agents ou l'apprentissage par renforcement.

6.3 Limites de l'Étude

Plusieurs limites méritent d'être soulignées. Premièrement, les gains observés restent modestes en valeur absolue, ce qui est cohérent avec la faible séparabilité naturelle des clusters dans un espace de données financières normalisées. Deuxièmement, le coût computationnel de la version améliorée est 63,5 fois supérieur à celui du classique, ce qui peut être prohibitif pour des applications nécessitant une exécution en temps réel. Troisièmement, l'absence de labels ground truth pour le dataset Credit Card limite l'évaluation à des métriques internes.

6.4 Recommandations Pratiques

Sur la base des résultats expérimentaux, les recommandations suivantes sont formulées pour une application en contexte bancaire réel. L'initialisation K-Means++ devrait être adoptée systématiquement en remplacement de l'initialisation aléatoire, son surcoût computationnel étant négligeable par rapport au gain en stabilité. Le seuil MAD devrait être ajusté selon le niveau de contamination des données brutes : un seuil de 2,5 est adapté pour des données prétraitées, tandis qu'un seuil de 3,0 convient mieux à des données brutes. Enfin, une validation systématique par plusieurs métriques complémentaires et plusieurs runs est recommandée avant toute prise de décision basée sur les segments obtenus.

7 Conclusion et Perspectives

7.1 Synthèse des Contributions

Ce travail a présenté une amélioration structurée de l'algorithme K-Means classique, intégrant trois composantes complémentaires validées par la littérature scientifique. L'expérimentation conduite sur un dataset de 8 950 clients bancaires a permis de démontrer une amélioration de +9,9 % du score Silhouette, une réduction de -4,4 % de l'écart-type sur 50 exécutions, et la robustesse de l'approche sur quatre datasets de nature différente. L'étude d'ablation a clairement identifié l'initialisation K-Means++ comme la composante apportant le gain le plus significatif.

7.2 Perspectives de Recherche

Plusieurs extensions futures sont envisageables pour renforcer les contributions de ce travail. Sur le plan de la robustesse statistique, l'augmentation du nombre de runs à 100 ou plus et l'utilisation de méthodes de test non paramétriques plus puissantes permettraient d'affiner les conclusions. Sur le plan algorithmique, l'implémentation d'un MAD multivarié basé sur la distance de Mahalanobis robuste offrirait une détection d'outliers plus adaptée aux données en haute dimension. Enfin, l'introduction de mécanismes de communication inter-agents et d'apprentissage par renforcement pour adapter dynamiquement les paramètres de clustering ouvrirait la voie à un véritable clustering agentif adaptatif.

8 Références Bibliographiques

Articles Scientifiques

Références

- [1] [1] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281–297.
- [2] [2] Arthur, D., & Vassilvitskii, S. (2007). k-means++ : The advantages of careful seeding. *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, 1027–1035. <https://doi.org/10.1145/1283383.1283494>
- [3] [3] Rousseeuw, P. J., & Croux, C. (1993). Alternatives to the Median Absolute Deviation. *Journal of the American Statistical Association*, 88(424), 1273–1283. <https://doi.org/10.1080/01621459.1993.10476408>
- [4] [4] Rousseeuw, P. J. (1987). Silhouettes : A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- [5] [5] Davies, D. L., & Bouldin, D. W. (1979). A Cluster Separation Measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1(2), 224–227. <https://doi.org/10.1109/TPAMI.1979.4766909>
- [6] [6] Calinski, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics — Theory and Methods*, 3(1), 1–27. <https://doi.org/10.1080/03610927408827101>
- [7] [7] Ferber, J. (1999). *Multi-Agent Systems : An Introduction to Distributed Artificial Intelligence*. Addison-Wesley.
- [8] [8] Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1), 193–218.

Datasets et Ressources

- [9] [9] Bhasin, A. (2018). Credit Card Dataset for Clustering. Kaggle. <https://www.kaggle.com/datasets/arjunbhasin2013/ccdata>
- [10] [10] Scikit-learn Developers. (2026). Scikit-learn : Machine Learning in Python. <https://scikit-learn.org>

Ouvrages de Référence

- [11] [11] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
- [12] [12] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.